HPC-Forest : évaluer l’optimisation de code par des modèles de langage

Recherche arborescente, correction observable et passage à l’échelle sur CPU ARM64

Nicolas Marano · Romain Despoullain

Rapport de recherche expérimental · Version du 19 octobre 2026 · Données scientifiques admises arrêtées à 18/10/2026 à 05 h 03 UTC · Suivi technique et remesure R2h : 19/10/2026 à 08 h 40 UTC

Résumé

L’optimisation de code par un modèle de langage pose un problème de mesure autant que de génération : un programme apparemment rapide peut être faux, un avantage sur quelques entrées peut disparaître en confirmation, et une accélération séquentielle ne démontre pas l’utilisation de plusieurs cœurs. Nous présentons HPC-Forest, un dispositif expérimental qui associe la recherche AB-MCTS, des propositions de programmes, des contrôles de correction et une sélection confirmée. L’étude comprend vingt recherches sur count 2023, couvrant quatre identités de modèles et cinq niveaux d’effort, quatre couvertures de quatorze autres sujets avec Luna, Astra, Terra et Sol MAX, trois couvertures Luna, Astra et Terra xhigh des mêmes quatorze sujets, deux campagnes DeepSeek, une comparaison de six recherches GPT avec ou sans harnais, GPT96 sur trois sujets et quatre cohortes source-only de quinze recherches chacune, Luna, Astra, Terra et Sol MAX. Les expériences sont analysées dans leur protocole propre, sans classement global des modèles.

Les vingt recherches count confirment une réduction du temps dans dix-neuf cellules sur vingt, comprise entre 39,78 % et 90,68 % pour les programmes modifiés retenus ; une cellule conserve la référence. Les couvertures Luna, Astra et Sol conservent la référence sur tropical et Sokoban ; Terra retient neuf programmes modifiés sur quatorze sujets et conserve cinq références. Dans la comparaison GPT, les meilleurs programmes des deux bras réduisent fortement les temps sur les trois charges, mais une seule recherche par bras et les incidents de transfert empêchent d’attribuer un avantage causal général au harnais. Les quatre cohortes source-only MAX confirment cinquante et un programmes modifiés sur soixante recherches ; neuf références sont conservées, sans établir un avantage causal du harnais. Une analyse postérieure, sans modification des exécutables, rassemble 11 575 chronométrages sur 10 allocations et sept sujets. Elle révèle des comportements contrastés, dont une accélération de 15,27 fois entre un et seize cœurs pour un programme N-body, et des courbes presque plates pour d’autres programmes pourtant rapides. Les résultats documentent des gains locaux dont les calculs sont reproductibles à partir des traces conservées ; ils ne certifient ni la correction universelle, ni un rang de concours, ni une supériorité générale des modèles ou de l’architecture.

Mots-clés : optimisation de programmes ; modèles de langage ; AB-MCTS ; benchmark ; OpenMP ; reproductibilité.

1. Introduction

Un modèle de langage peut proposer une modification plausible d'un programme sans fournir une amélioration utilisable. La proposition doit compiler, respecter le comportement attendu et accélérer une charge mesurée. Lorsque plusieurs propositions sont explorées, leur sélection ajoute un risque : retenir le meilleur temps de recherche favorise aussi les fluctuations de mesure et les erreurs que les premiers contrôles n'ont pas révélées. Un dispositif d'évaluation doit donc relier chaque résultat à son programme, à ses entrées, à son protocole et à une confirmation distincte.

HPC-Forest étudie cette chaîne sur des programmes issus des archives du Marathon de programmation parallèle de la SBC [4]. Il utilise TreeQuest 0.3.2 et sa politique AB-MCTS-A. AB-MCTS organise l'exploration entre de nouvelles propositions et le raffinement de propositions existantes à partir d'un retour externe ; il constitue ici le mécanisme de recherche, et non une méthode nouvelle revendiquée par les auteurs [1, 2]. L'apport du présent travail réside dans l'instrumentation, la vérification et l'analyse conjointe des recherches, de leurs échecs et des exécutables finalement conservés.

Trois questions guident l'analyse. Premièrement, quels gains sont effectivement confirmés sur les charges préparées, et quelles références restent préférables ? Deuxièmement, que peut-on observer lorsque la génération dispose d'un harnais de compilation, de tests de développement et de lecture documentaire ? Troisièmement, les programmes retenus profitent-ils de ressources CPU supplémentaires lorsque leurs octets et leurs entrées restent identiques ? Ces questions exigent des unités d'analyse différentes : une recherche indépendante, un appel de modèle, un sommet de l'arbre et une répétition de chronométrage ne constituent pas des observations interchangeables.

L'article présente les résultats reçus et audités à une date explicite. La priorité humaine actuelle est MAX uniquement : R1 MAX et les quatre groupes source-only MAX sont complets, 60/60 chacun. Les efforts inférieurs restent des résultats ou plans historiques conservés, sans préalable de couverture à poursuivre. GPT96 est reçu sur ses trois sujets avec des plannings limités par budget. La reprise R2h du supplément nombres premiers a réconcilié les trois appels Sol MAX et leurs 59 037 jetons exacts, sans consommation inconnue. Une remesure sur une allocation distincte confirme le candidat figé : 43,85 ms pour la référence contre 4,91 ms pour le candidat, soit 88,80 % de temps en moins et une accélération de 8,93. Douze entrées certifiées et cinq paires de mesures sont vérifiées. Ce résultat porte sur cette paire et ce benchmark, avec la même implémentation de l'Evaluator ; il reste séparé des quatorze cohortes historiques. L'audit natif final après arrêt est clos avec ses limites explicites : trois appels, cinq confirmations et 52 fichiers de cache sont réconciliés. R3 avec implémentation corrigée R4b reste bloqué techniquement et R5 n'est pas lancé. Les annexes distinguent ces états techniques des résultats scientifiques admis.

2. Matériel et méthodes

2.1. Périmètre, cohortes et unités d'analyse

Les archives recensent dix-neuf sujets entre 2020 et 2023. Quinze sont admis dans R1 après préparation ; quatre restent exclus pour domaine ou observabilité. Les pages consultées pour 2024 et 2025 ne fournissent pas de nouveaux sujets exploitables. Le plan historique de 300 cellules correspond à quinze sujets, quatre modèles et cinq efforts ; il ne constitue plus la priorité humaine actuelle. Les 118 cellules R1 reçues de cet instantané comprennent les vingt count, quatorze autres sujets par modèle MAX, puis trois couvertures xhigh de quatorze sujets. Leur sous-ensemble MAX couvre 60/60 cellules, sans effacer les observations non-MAX historiques. Une recherche conserve une seule graine, fixée à 23.

Le tableau 1 définit les ensembles utilisés. Ils se recouvrent : les programmes d'une recherche peuvent ensuite apparaître dans une analyse CPU. Additionner les tailles des cohortes donnerait donc un nombre

trompeur d'expériences indépendantes. Une campagne désigne une racine complète de résultats ; deux bras partageant un job et un sujet restent deux campagnes distinctes.

Tableau 1 — Périmètre des données. Les ensembles se recouvrent ; leurs tailles ne s'additionnent pas.

Ensemble	Recherches reçues	Rôle dans l'étude
R1 · count 2023	20 cellules / une graine chacune	Quatre modèles × cinq efforts
R1 · couverture Luna MAX	14 cellules supplémentaires	Autres sujets admis ; mêmes contrats, temps propres
R1 · couverture Astra MAX	14 cellules supplémentaires	Même préparation ; références propres
R1 — couverture Terra MAX	14 cellules supplémentaires	Contrats et références propres
R1 · couverture Sol MAX	14 cellules supplémentaires	Contrats finis ; références propres
DeepSeek local	2 campagnes × 3 sujets	Résultats et coûts locaux ; deux versions
GPT · avec/sans harnais	6 bras / 3 paires	Comparaison descriptive ; une recherche par bras
Diagnostics CPU postérieurs	58 racines / 10 allocations	Mêmes exécutables ; 2 315 points / 11 575 temps
Explorations antérieures	42 résumés historiques	Provenance et négatifs ; pas un échantillon homogène
GPT96 sans harnais	3 recherches reçues / planning incomplet	177 appels observés ; contrats finis ; budgets atteints
Source-only Luna MAX	15 recherches reçues ; plan historique distinct	Harnais interne désactivé ; mère et contrôle externe conservés
R1 · couverture Luna xhigh	14 cellules supplémentaires	Contrats finis ; références propres
R1 · couverture Astra xhigh	14 cellules supplémentaires	Réception antérieure ; compteurs incomplets conservés
Source-only Astra MAX	15 recherches fraîches supplémentaires	Réception antérieure ; compteurs incomplets conservés
R1 Terra xhigh / source-only Terra MAX	14 / 15 recherches supplémentaires reçues	Historique R1 reçu ; MAX R1 complet 60/60
Source-only Sol MAX	15 recherches supplémentaires ; MAX 60/60 reçu	104 missions / 91 sommets ; 14 programmes modifiés
Véritable Codex / R3 corrigé R4b / R5	Aucun résultat natif admis	Barrières et qualifications propres en attente

Les identifiants GPT sont les identités exactes transmises et enregistrées par l'interface native. Les efforts max, xhigh, high, medium et low sont des paramètres de génération, pas des durées de calcul garanties. Les noms locaux DeepSeek et Qwen désignent les modèles chargés par Ollama dans les campagnes concernées. Ces identités documentent la configuration effective sans constituer une certification indépendante des poids d'un service hébergé.

2.2. Forêt fixe et retour de mesure

Dans R1, trois rôles d'exploration, A, B et C, disposent chacun d'un arbre AB-MCTS-A. Le rôle G produit des intégrations, elles-mêmes compilées, contrôlées et mesurées. Une mère modèle intervient au plus deux fois, pour la préparation et la synthèse ; elle propose les orientations à partir des données autorisées de la recherche. Les rôles sont fixes dans cette version. La génération variable d'axes et le conseil renouvelé branche par branche appartiennent à R4 et ne décrivent pas les résultats R1.

L'interface ask/tell persiste les requêtes, les états et les retours de TreeQuest. Le code du parent enregistré constitue le point de départ d'un raffinement ; une intégration porte une liste distincte de programmes sources. Les liens de parenté MCTS, les indications de rôle et les sources d'intégration sont donc représentés différemment dans les figures. Le score fourni à la recherche vaut zéro pour un résultat incorrect ou non compilable. Pour un résultat valide, il est défini par $q = 1 / (1 + T/T_0)$, où T est le temps moyen du programme et T_0 celui de la référence de recherche. Ce score borné n'est pas le pourcentage de

réduction présenté dans les résultats. Une interruption d'infrastructure sans mesure utilisable ne reçoit pas artificiellement un score algorithmique nul.

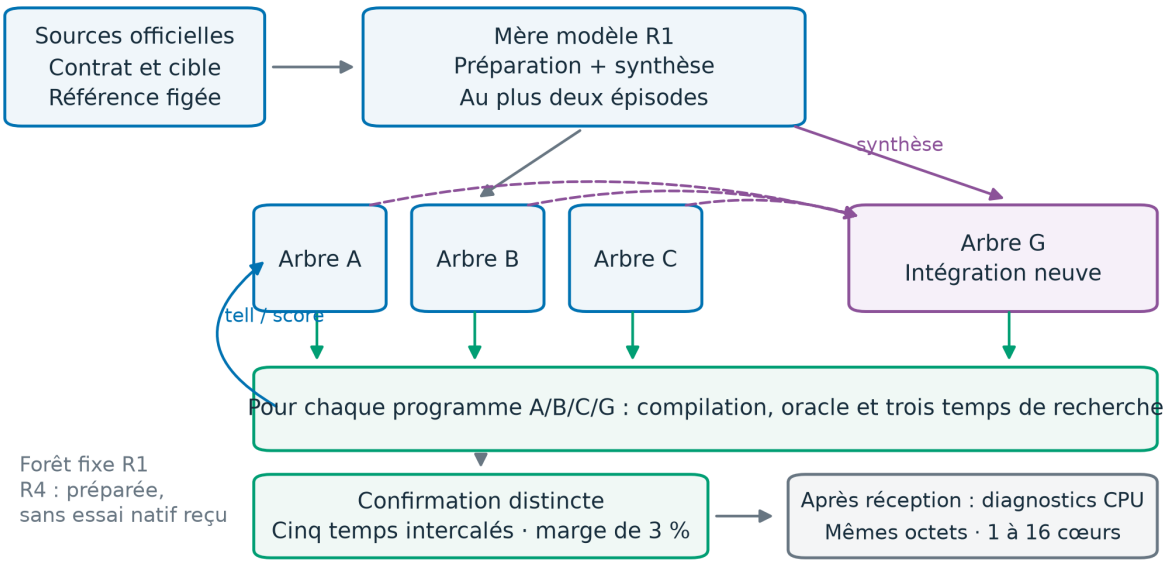


Figure 1 — Protocole effectivement utilisé dans R1. Les trois arbres A/B/C sont fixes. La mère prépare des orientations puis une synthèse ; G constitue un programme neuf. Les contrôles de recherche, les confirmations et les diagnostics CPU sont des étapes distinctes. R4 est une extension préparée, sans résultat natif dans cet instantané.

R1 prévoit au plus huit missions de programme et deux épisodes de mère par cellule, avec 1 800 secondes et 1,5 million de jetons de budget. Une mission avec harnais peut répartir sa génération sur trois appels au maximum, dans une fenêtre totale de 600 secondes. Ces plafonds n'impliquent ni huit programmes valides, ni dix appels effectivement mesurés. Le tableau 2 situe les autres protocoles ; leurs différences empêchent de traiter toutes les campagnes comme une ablation unique.

Tableau 2 — Les créneaux prévus sont des maxima de planification, distincts des appels et sommets réalisés.

Protocole	Programmes prévus par recherche	Plafonds et harnais
R1	8 programmes + au plus 2 épisodes de mère	30 min ; 1,5 M jetons ; harnais ≤ 3 appels/mission
Comparaison GPT	24 programmes par bras	2 h ; 1,5 M jetons ; avec/sans harnais ; pas de mère modèle
Source-only Luna/Astra/Terra/Sol MAX	8 programmes + 2 épisodes de mère	30 min ; 1,5 M jetons ; harnais interne désactivé ; contrôle externe
DeepSeek v11	96 programmes par sujet	4 cycles ; 6 A/B/C et 6 G par cycle ; génération Ollama
GPT96 (reçu)	96 prévus ; 54 / 54 / 75 missions réalisées	6 h ; 4 M jetons ; harnais désactivé ; contexte natif 65 536
CPU postérieur	Aucune génération	1 chauffe + 5 passages à 1/2/4/8/16 cœurs

2.3. Harnais, autonomie et contrôle de l’opérateur

Le harnais fournit un environnement mécanique : compilation, tests de développement, diagnostics et accès HTTPS à des domaines préparés. Les lectures doivent être choisies par le modèle et laisser une trace. Les jeux réservés à la confirmation et le score interne de recherche ne sont pas communiqués comme outils de développement. Un programme correct termine l’épisode interne ; une correction autonome peut donc consommer plusieurs appels sans créer plusieurs sommets de recherche.

L’opérateur prépare les sources, les formats, les oracles, les compilateurs et les ressources. Il n’écrit ni ne répare les candidats, ne choisit pas une solution à leur transmettre et ne réinjecte pas le présent rapport dans les recherches. Les pannes de transport sont traitées par une reprise documentée de la même session, avec registre des requêtes commencées et cache des réponses produites. Une recherche ne recommence pas pour effacer une sortie fausse, un doublon, une stagnation ou une expiration bornée.

Les règles d’isolation ont une portée versionnée. R1 dispose de plans de préparation et de synthèse pour ses rôles fixes ; il ne démontre pas le conseil actif répété par branche demandé pour R4. Dans l’extension R4, chaque conseil local doit utiliser seulement l’histoire de la branche destinataire et les faits de cible. La récolte globale reste un canal séparé. Les tests mécaniques de cette propriété ne remplacent pas son observation au cours de recherches natives.

2.4. Cibles matérielles et préparation des problèmes

Les programmes candidats sont évalués sur ARM64, avec quatre cœurs CPU et zéro GPU pour les campagnes principales. Les modèles GPT utilisent une inférence hébergée, appelée par la CLI du PC ; leurs poids et leur vitesse interne de décodage ne sont pas observables ici. Les campagnes DeepSeek réservent quatre cœurs ARM64 et deux GPU pour l’inférence locale, tandis que les candidats restent exécutés sur CPU sans GPU. Les ressources de l’inférence, celles du programme optimisé et celles du processus de contrôle sont rapportées séparément dans les annexes.

Les compilateurs et leurs options, les sources officielles, les contrats d’entrée/sortie et les variables d’environnement sont conservés avec leurs empreintes. Un nombre de CPU visible à l’échelle du nœud ne remplace pas l’allocation Slurm. De même, l’option de compilation OpenMP ne prouve pas le nombre de cœurs effectivement utilisés. Aucun temps d’inférence natif, prix d’API ou volume de mémoire GPU n’est déduit d’une donnée qui ne le mesure pas.

Les sujets sont adaptés à une cible expérimentale contrôlée, ce qui impose des qualifications de conformité. N-body suit notamment le compteur d’en-tête présent dans la source C, mais absent de la description en prose. Les tests de permutations reçus utilisent des symboles distincts. La revue complémentaire de quicksort confirme les sorties MD5 sur les cas archivés, tout en identifiant un candidat hybride avec insertion et repli heapsort : sa fidélité stricte à l’algorithme demandé n’est pas certifiée. Les quatre exclusions de préparation et les domaines finis sont détaillés en annexe A.

2.5. Correction, confirmation et sélection

La correction observable repose sur un oracle exact pour les entrées préparées. Les jeux de recherche et de confirmation possèdent des empreintes distinctes. Le temps utilisé pour comparer les programmes est celui de la charge de benchmark du contrat, comprenant le lancement et les entrées/sorties prévus par le harnais. Il ne s’agit pas nécessairement du temps d’un noyau de calcul isolé. Les campagnes principales utilisent une chauffe, trois mesures pendant la recherche et cinq mesures en confirmation, intercalées entre les finalistes et la référence.

Le gagnant admissible est sélectionné après confirmation. La référence est conservée si aucun candidat correct n’atteint la marge requise de 3 %. Les sorties fausses en confirmation restent des résultats négatifs

: elles ne reçoivent pas de temps exploitable et ne peuvent pas gagner la sélection. Les temps de confirmation sont utilisés dans les tableaux de performance ; les temps de recherche servent à documenter le chemin de recherche.

En notant T_0 la moyenne de la référence et T celle du programme retenu dans la même campagne, la réduction est $g = 100 \times (1 - T/T_0)$ %, l'accélération est $S = T_0/T$ et le temps économisé est $\Delta T = T_0 - T$. Ces quantités ne sont pas additives entre transformations ou entre sujets. Les tableaux donnent la moyenne et l'écart-type empirique des cinq chronométrages ; cet écart-type décrit la dispersion de mesure d'un exécutable, pas la variabilité de cinq recherches indépendantes. Les précautions de mesure et d'interprétation suivent les principes de transparence du benchmarking scientifique [3, 5].

2.6. Mesures postérieures de montée en cœurs

Les 10 lots CPU réexécutent uniquement des exécutables issus de campagnes reçues et auditées. Aucun candidat, oracle ou binaire n'est modifié ; il n'y a ni nouvel appel de modèle ni recompilation. Une allocation possède seize cœurs physiques ARM64, 16 Gio de mémoire et zéro GPU. Les affinités donnent successivement accès à 1, 2, 4, 8 et 16 cœurs. Chaque configuration reçoit une chauffe et cinq mesures, dans des ordres intercalés conservés.

L'accélération de montée en cœurs vaut $S_p = T_1/T_p$ pour le même binaire et la même entrée dans la même allocation ; son efficacité vaut $E_p = S_p/p$. Elle doit être distinguée de l'accélération par rapport au programme de référence à nombre de cœurs égal. Les rapports CPU/mural issus des compteurs du processus enfant servent de diagnostic d'occupation moyenne. Ils ne donnent pas une trace exacte du nombre de threads, et les coûts de lancement ou d'entrées/sorties restent inclus.

L'unicité d'une mesure s'appuie sur le triplet empreinte du binaire, empreinte de l'entrée, nombre de cœurs. Les références partagées deviennent des alias, avec un reçu ; elles ne sont pas comptées comme des optimisations indépendantes. Les 2 315 points comprennent 1 865 combinaisons distinctes et 450 contrôles répétés entre allocations. Aucune moyenne ne fusionne ces allocations. Les grands jeux supplémentaires de count, dépourvus de sortie attendue dans le plan, sont comparés à la sortie de la référence canonique exécutée dans le lot ; les autres cas conservent leurs sorties attendues archivées. Cette différence de provenance de l'oracle reste visible dans les données d'audit.

2.7. Comptabilité et audit de l'article

La comptabilité native déduplique les appels par session et nonce. Le total exact connu est la somme des jetons d'entrée et de sortie ; les jetons d'entrée en cache sont déjà inclus dans l'entrée et les jetons de raisonnement dans la sortie. Une réservation ou une charge conservatrice d'expiration n'est jamais ajoutée à la consommation exacte. Les appels sans compteur final, les appels encore en cours et les sondes techniques restent identifiés. Les comptes Ollama sont conservés séparément des comptes natifs.

La présente édition recalcule les résultats à partir de 209 registres SQLite ouverts en lecture seule et des 10 lots bruts. Elle vérifie les moyennes, les écarts-types, les médianes, les réductions, les rapports CPU/mural, les affinités, les tours intercalés et les identités d'entrée/binaire. Les empreintes des fichiers scientifiques sont contrôlées avant et après lecture. Cet audit documentaire n'exécute aucun programme candidat et n'ajoute aucune recherche. Les exports de calcul, le relevé des vérifications et l'index des sources permettent de distinguer les données reçues des résumés historiques.

3. Résultats

3.1. Vingt couples modèle–effort sur count 2023

La figure 2 présente les vingt réductions confirmées. Les contrats et les entrées pertinents sont identiques entre cellules, mais chaque référence garde les chronométrages de son allocation. Dix-neuf cellules retiennent un programme modifié. Luna medium conserve la référence. Les résultats ne suivent pas une relation monotone simple avec l'effort : sur cette graine, Terra high dépasse Terra max, et Sol low dépasse Sol xhigh. Ces observations décrivent les recherches reçues ; elles ne permettent pas d'inférer une hiérarchie générale des efforts ou des modèles.

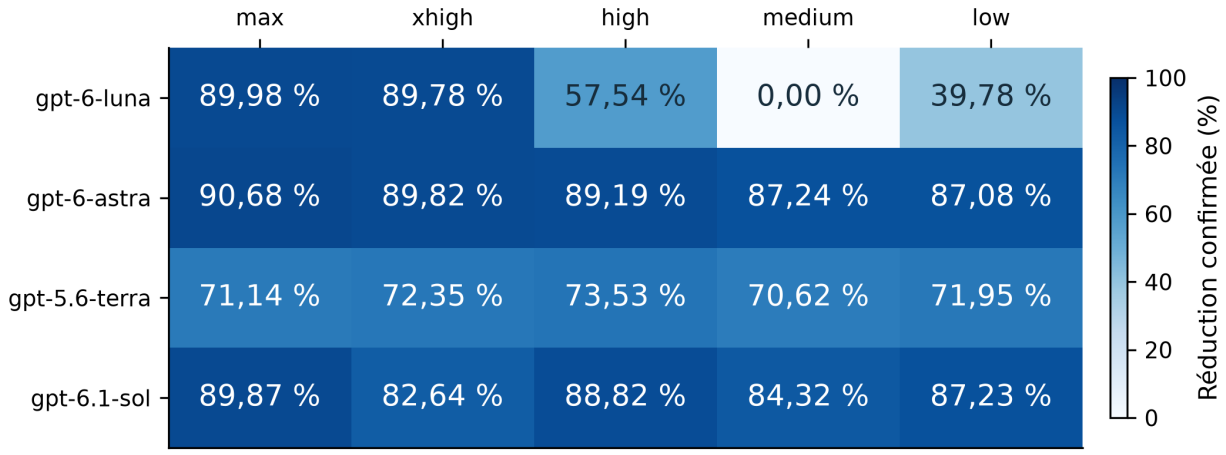


Figure 2 — Réduction confirmée du temps sur count 2023, en pourcentage de la référence de chaque cellule. Chaque case représente une seule recherche, graine 23. La référence conservée apparaît explicitement à 0 %. Les vingt contrats sont comparables ; les chronométrages de référence ne sont pas fusionnés. Les moyennes, écarts-types et coûts de chaque cellule figurent en annexe B.

Tableau 3 — Appels et jetons observés sur les cinq efforts de chaque identité, count 2023. Les compteurs incomplets restent des minima connus ; cette somme ne classe pas l'efficacité générale des modèles.

Identité	Appels (5 efforts)	Jetons exacts connus	Appels non mesurés
GPT 6-luna	61	1 069 235	0
GPT 6-astra	45	729 707	2
GPT 5.6-terra	48	741 551	3
GPT 6.1-sol	47	771 068	2

Les 201 appels natifs de cette grille possèdent 3 311 561 jetons exacts connus ; sept appels restent non mesurés. Le nombre de sommets et les budgets effectivement consommés varient, notamment en présence d'interruptions ou de doublons. Ces différences limitent une lecture des gains comme un simple effet du modèle. L'ensemble LOW totalise cinquante appels et 743 280 jetons exacts ; les réparations internes éventuelles ne sont pas comptées comme de nouveaux sommets.

3.2. Couvertures Luna, Astra, Terra et Sol MAX sur quatorze autres sujets

Luna MAX, Astra MAX et Sol MAX retiennent chacun un programme modifié sur douze des quatorze autres sujets ; tropical et Sokoban conservent leur référence. Les quatorze contrats sont identiques après exclusion du seul chronométrage de référence propre à chaque allocation. La figure 3 juxtapose les réductions confirmées des quatre couvertures sans fusionner leurs temps ni calculer une moyenne de qualité générale. Chaque cellule possède une seule recherche et la graine 23 ; les écarts descriptifs ne constituent pas un classement des modèles. Les gains quicksort ne certifient pas la fidélité à l'algorithme demandé : la revue de l'hybride Luna ne qualifie pas automatiquement les programmes Astra, Terra ou Sol.

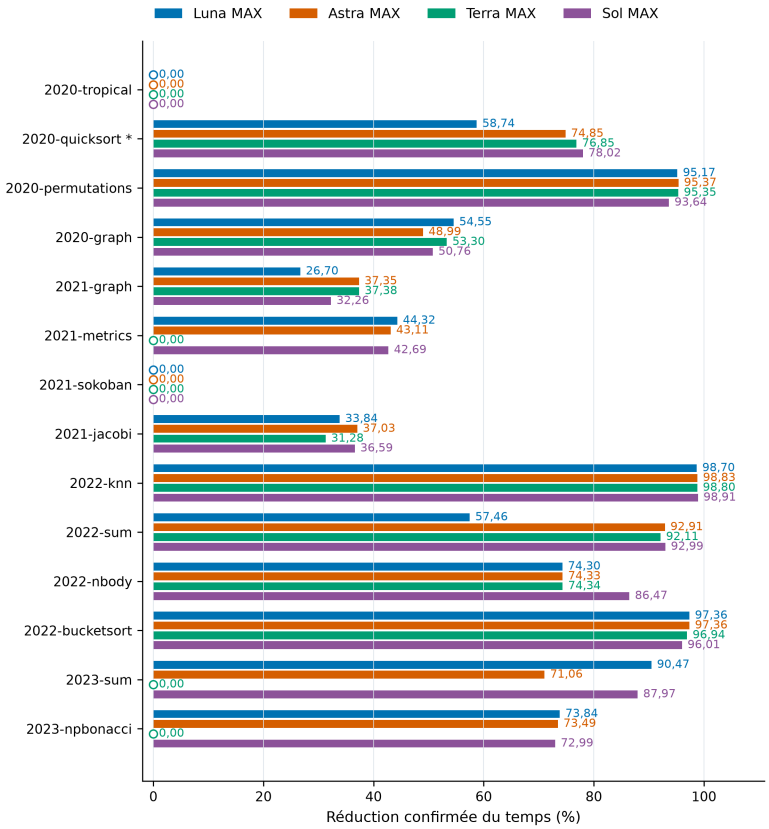


Figure 3 — Réductions confirmées des quatorze sujets pour Luna MAX, Astra MAX, Terra MAX et Sol MAX. Les symboles ouverts indiquent une référence conservée. Chaque valeur vient d'une recherche distincte et de sa propre référence. Les barres ne représentent ni une probabilité de succès ni une significativité statistique ; les cinq temps sont disponibles en annexe. L'astérisque de quicksort signale la réserve de fidélité algorithmique.

Luna compte 110 sommets notés et 154 appels, soit 3 774 478 jetons exacts ; neuf propositions sont réparées avec succès, avec deux doublons et un programme Jacobi 2021 incorrect conservés. Astra compte 40 sommets et 71 appels, soit 1 144 204 jetons exacts connus, avec 17 appels non mesurés et aucune réparation réussie. Ses 27 interruptions d'infrastructure, parmi 67 missions enregistrées, ne sont pas des programmes faux. La profondeur maximale des sommets notés est deux pour Luna et un pour Astra. Les plafonds de créneaux n'ont donc pas produit les mêmes parcours ni les mêmes dépenses ; une comparaison des seuls gains masquerait cette différence.

Terra MAX confirme neuf programmes modifiés ; tropical, metrics 2021, Sokoban, somme 2023 et npbonacci conservent leur référence. Les réductions des programmes modifiés vont de 31,28 % à 98,80 % sur leurs charges préparées. Ses 47 missions comprennent 17 programmes valides, un incorrect et 29 interruptions d'infrastructure, pour 18 sommets mesurés. La réconciliation compte 58 invocations observées, 980 971 jetons exacts connus et 24 invocations sans compteur ; une requête expirée sans réponse n'a pas de consommation connue. La panne de transfert et la livraison tardive à octets identiques

sont conservées, sans régénération. Les budgets maximaux, parcours effectifs et coûts incomplets empêchent d'en déduire un classement général. Aucun exécutable Terra de cette couverture n'a encore de mesure postérieure de montée en cœurs dans cette édition.

Sol MAX confirme douze programmes modifiés, avec des réductions de 32,26 % à 98,91 % sur les charges préparées. Ses 92 missions comprennent 81 valides et onze erreurs d'infrastructure, pour 81 sommets notés. Les 113 requêtes sont livrées et réconciliées : 110 invocations natives, 2 502 330 jetons exacts connus et huit invocations sans compteur ; trois requêtes ont expiré avant invocation. Le relais est arrêté après audit et réconciliation, et la même file R1 a ensuite reçu Terra xhigh sous allocation750909, désormais close. Ces traces ne fournissent ni coût total exact ni nouvelle mesure de montée en cœurs.

L'exemple de la figure 4 montre la forêt reçue de k-NN Luna MAX. Les directions déclarées par les modèles et les transformations archivées sont des observations textuelles, et non une reconstruction de leur pensée interne. Les huit programmes notés ne sont pas les dix appels natifs de la cellule ; les épisodes de mère sont comptabilisés séparément.

L'inspection des deux programmes retenus k-NN et N-body précise ce que ces gains recouvrent. Le premier remplace la maintenance linéaire des voisins par un tas maximal de taille bornée et utilise un ordinal pour conserver l'ordre des points à distance égale. Le second sépare les champs des particules en tableaux contigus et réutilise une région parallèle OpenMP entre les itérations, avec synchronisation des phases. Ces éléments sont présents dans le code conservé et cohérents avec les transformations déclarées. Ils décrivent les programmes produits ; aucune ablation ne permet d'attribuer une part du gain à chaque transformation isolée.

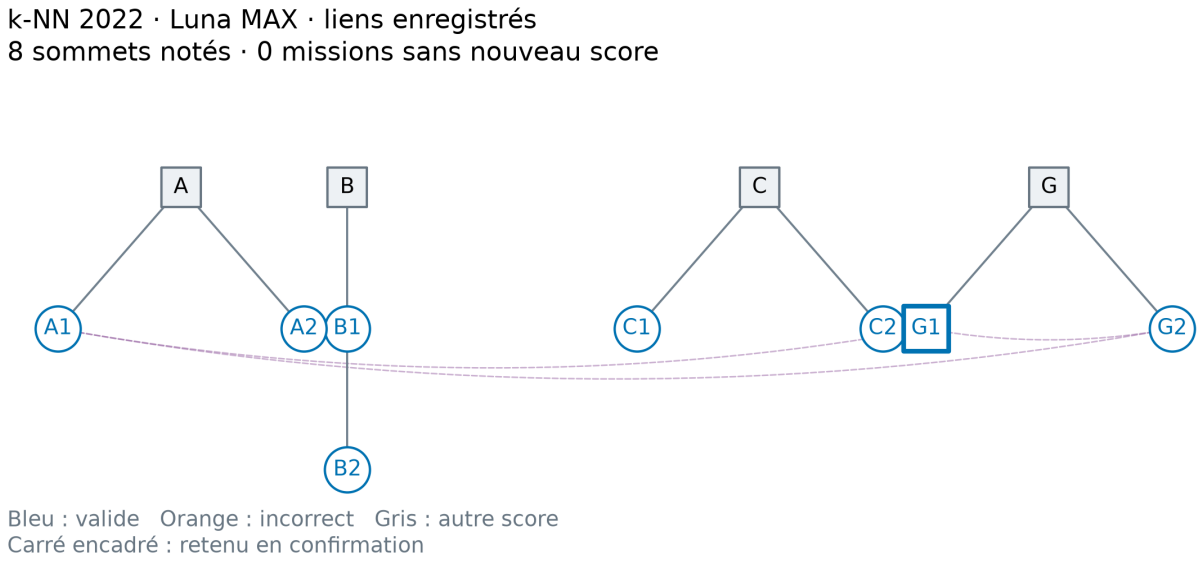


Figure 4 — Forêt réellement enregistrée pour k-NN 2022, Luna MAX. Les segments pleins représentent les parents de recherche ; les pointillés représentent les sources d'une intégration. Les racines A/B/C/G sont des rôles de structure. Chaque autre nœud correspond à un essai noté, identifié dans l'export JSON. Les couleurs indiquent le statut observable ; l'encadrement marque le programme retenu après confirmation. Les statuts des nœuds proviennent de la recherche ; la sélection encadrée provient de la confirmation.

La couverture Luna xhigh est également reçue sur les quatorze autres sujets : treize programmes modifiés confirmés, tropical conservant sa référence. Ses 112 missions comprennent 108 valides et quatre incorrectes, avec 112 sommets notés. Les 158 requêtes sont livrées et réconciliées ; les 158 invocations comptent 3 434 224 jetons exacts, sans compteur manquant pour cette cohorte. L'annexe C.6 donne les cinq confirmations de chaque référence et programme retenu. Les contrats correspondent aux couvertures MAX après exclusion du seul temps de référence, mais leurs chronométrages restent propres aux allocations. Une seule graine et l'ordre temporel ne permettent pas de conclure à une hiérarchie

causale des efforts. Aucun nouveau diagnostic de montée en cœurs ni qualification algorithmique stricte de quicksort n'est ajouté.

La couverture Astra xhigh reçoit également quatorze sujets : douze programmes modifiés confirmés, tropical et Sokoban conservant leur référence. Ses 95 missions comprennent 80 valides, quatorze erreurs d'infrastructure et une génération échouée, pour 80 sommets notés. Les 118 requêtes sont livrées et réconciliées : 115 invocations, 2 091 845 jetons exacts connus, douze invocations non mesurées et trois expirations avant invocation. Les coupures de livraison sont conservées sans rejeu ; elles limitent encore la comparaison. L'annexe C.8 donne les cinq confirmations de chaque référence et programme retenu. Les contrats correspondent aux couvertures MAX après la seule exclusion du temps de calibration ; les chronométrages ne sont pas fusionnés.

La couverture R1 Terra xhigh reçoit 14 recherches et confirme 11 programmes modifiés ; 3 références sont conservées. Les 87 missions comprennent 68 valides, pour 69 sommets notés. Les 113 requêtes sont toutes réconciliées ; 110 réponses sont livrées. Les 104 invocations ont 1 966 540 jetons exacts connus et 7 invocations sans mesure finale. La consommation reste inconnue pour 9 requêtes, sans convertir l'absence de réponse en appel nul. Les cinq confirmations et les négatifs sont détaillés en annexe C.9. Les contrats finis et les temps propres aux allocations sont conservés, sans rejeu ni classement causal.

3.3. Quatre cohortes source-only sur les quinze sujets

Le groupe Luna MAX source-only reçoit quinze recherches fraîches, soit les quinze premières issues de ce bras. Quatorze programmes modifiés sont confirmés ; Sokoban conserve sa référence. Les réductions des programmes modifiés vont de 5,13 % à 98,68 % sur les contrats finis. Les quinze contrats correspondent aux références R1 après exclusion du seul temps de calibration, mais les temps des allocations restent distincts. Le tableau 4 résume les cinq confirmations de chaque référence et programme retenu.

Tableau 4 — Source-only Luna MAX : quinze racines fraîches, moyenne ± écart-type de cinq confirmations. Une seule graine ; références propres à cette allocation.

Sujet	Référence (s)	Retenu (s)	Réduction (%)
2020-tropical	0,01023 ± 0,00042	0,00970 ± 0,00040	5,13
2020-quicksort	0,06885 ± 0,00024	0,01722 ± 0,00037	74,99
2020-permutations	0,13273 ± 0,00128	0,00637 ± 0,00011	95,20
2020-graph	0,01184 ± 0,00030	0,00559 ± 0,00022	52,76
2021-graph	0,00836 ± 0,00014	0,00609 ± 0,00026	27,11
2021-metrics	0,00965 ± 0,00015	0,00655 ± 0,00021	32,15
2021-sokoban	0,00465 ± 0,00021	0,00465 ± 0,00021	0,00
2021-jacobi	0,06591 ± 0,00060	0,04396 ± 0,00017	33,30
2022-knn	2,05154 ± 0,06945	0,02703 ± 0,00028	98,68
2022-sum	0,12642 ± 0,00152	0,05560 ± 0,00076	56,02
2022-nbody	0,66675 ± 0,00051	0,17541 ± 0,00062	73,69
2022-bucketsort	0,42101 ± 0,00225	0,01242 ± 0,00031	97,05
2023-sum	0,25144 ± 0,00050	0,02146 ± 0,00058	91,46
2023-npbonacci	0,02202 ± 0,00017	0,00897 ± 0,00034	59,26
2023-count	0,08111 ± 0,00035	0,02292 ± 0,00054	71,74

Le harnais interne est désactivé. La mère, les trois arbres A/B/C, les deux intégrations G et le contrôle externe restent présents ; il s'agit du générateur structuré source-only, distinct du véritable agent Codex à

outils. Les 120 missions comprennent 112 valides, cinq compilations échouées, deux sorties incorrectes et un doublon. Les 119 sommets notés incluent les rejets de compilation ou de correction et ne désignent pas autant de programmes chronométrés. Aucun négatif n'est réparé par l'opérateur ou rejoué.

Les 150 requêtes sont livrées et réconciliées, avec 150 invocations et 3 564 823 jetons exacts pour cette cohorte : trente appels de mère, quatre-vingt-dix d'enfants et trente d'intégration. Aucun compteur ne manque dans ce groupe. Ces observations complètent le bras descriptif ; une seule graine, l'ordre temporel et les interruptions présentes dans R1 empêchent d'estimer un avantage causal général du harnais. Aucun nouveau diagnostic de montée en cœurs ni qualification algorithmique stricte de quicksort n'est ajouté.

Le second groupe source-only, Astra MAX, reçoit quinze recherches fraîches et confirme quatorze programmes modifiés ; tropical conserve la référence. À sa réception, ce groupe portait le cumul historique à30/300 issues prévues ; cette ancienne grille ne constitue plus un préalable MAX. Ses 85 missions comprennent 66 valides, seize erreurs d'infrastructure, une génération échouée, une compilation échouée et une exécution échouée ; 68 sommets sont notés. Les 101 requêtes sont livrées et réconciliées : 98 invocations, 1 856 292 jetons exacts connus, treize invocations non mesurées et trois expirations avant invocation. La consommation totale exacte demeure inconnue. Les cinq confirmations et leurs dispersions figurent dans l'annexe C.7 ; ses temps restent propres à cette allocation. L'ancien chemin d'arrêt récursif après audit est documenté comme violation de procédure et retiré de l'usage. Aucune terminaison étrangère n'est établie.

Le troisième groupe source-only, Terra MAX, reçoit 15 recherches et confirme 9 programmes modifiés ; 6 références sont conservées. Les 49 missions comprennent 14 valides, pour 14 sommets notés. Les 64 requêtes sont toutes réconciliées ; 59 réponses sont livrées. Les 59 invocations ont 823 583 jetons exacts connus et 31 invocations sans mesure finale. La consommation reste inconnue pour 35 requêtes, sans convertir l'absence de réponse en appel nul. Les cinq confirmations et les négatifs sont détaillés en annexe C.10. Les contrats finis et les temps propres aux allocations sont conservés, sans rejeu ni classement causal.

Le quatrième groupe source-only, Sol MAX, reçoit quinze recherches et confirme quatorze programmes modifiés ; tropical conserve sa référence. Les 104 missions comprennent 90 valides, huit erreurs d'infrastructure, cinq générations échouées et une compilation échouée, pour 91 sommets notés. Les 124 requêtes sont réconciliées : 121 invocations CLI observées, 111 usages finaux mesurés, dix invocations de consommation inconnue et trois expirations prouvées avant invocation. Les 2 676 472 jetons exacts connus ne forment pas un total exact global. Une réponse tardive, absente de l'archive originale, est reçue séparément avec son marqueur ready et les mêmes octets. Les cinq confirmations et leurs dispersions figurent en annexe C.11 ; aucun temps n'est fusionné entre allocations. L'identité modèle/MAX demandée et les invocations CLI sont contrôlées ; le backend hébergé n'est pas attesté indépendamment.

Le bras source-only MAX est maintenant reçu et audité sur 60/60 issues : quatre modèles, quinze sujets chacun. Les anciennes grilles 300 + 300 sont historiques ; leur achèvement n'est plus un préalable humain.

3.4. DeepSeek : gains confirmés et rejets décisifs

Les deux campagnes DeepSeek sont reçues et auditées sur k-NN, somme et N-body. Le tableau 5 donne leurs temps de confirmation. V4-Flash conserve un programme modifié sur les trois charges. Pour 0731, les deux finalistes k-NN échouent au premier cas de confirmation : la référence est donc gardée et le gain final vaut zéro. Présenter leur temps de recherche comme un gain final aurait inversé le sens du résultat.

Tableau 5 — DeepSeek, moyenne ± écart-type empirique, cinq temps par programme. La référence est conservée pour k-NN 0731.

Version / sujet	Référence (s)	Retenu (s)	Réduction (%)
V4-Flash · knn	2,06309 ± 0,02231	0,02745 ± 0,00042	98,67
V4-Flash · sum	0,13176 ± 0,00098	0,01348 ± 0,00025	89,77
V4-Flash · nbody	0,67562 ± 0,00024	0,16350 ± 0,00028	75,80
V4-Flash-0731 · knn	2,09660 ± 0,04391	2,09660 ± 0,04391	0,00
V4-Flash-0731 · sum	0,13189 ± 0,00142	0,01051 ± 0,00029	92,03
V4-Flash-0731 · nbody	0,67117 ± 0,00044	0,15434 ± 0,00031	77,00

Les deux campagnes totalisent 11 416 821 jetons exacts locaux. Le débit de décodage Ollama pondéré de 0731 est d'environ 62,35 jetons de sortie par seconde, calculé comme la somme des jetons de sortie divisée par la somme des durées de décodage. Il ne s'agit ni d'un débit entrée-plus-sortie, ni d'une mesure comparable à un décodage GPT hébergé non observé. Le premier auditeur supposait à tort tous les finalistes corrects ; son échec est conservé. Un lecteur séparé, testé positivement et négativement, a revérifié l'exclusion des candidats incorrects et la sélection du gagnant admissible sans modifier les programmes, l'oracle ou les seuils.

3.5. Comparaison GPT avec et sans harnais

Les six bras de la comparaison utilisent des recherches fraîches, avec vingt-quatre créneaux prévus par bras. Chaque paire possède les mêmes empreintes d'entrées. Les trois références sont toutefois chronométrées dans leurs bras respectifs. La figure 5 montre les temps des programmes finalement retenus ; le tableau 6 donne les réductions associées. Le bras avec harnais termine plus vite sur N-body, tandis que les deux autres paires présentent des résultats proches à l'échelle des gains relatifs.

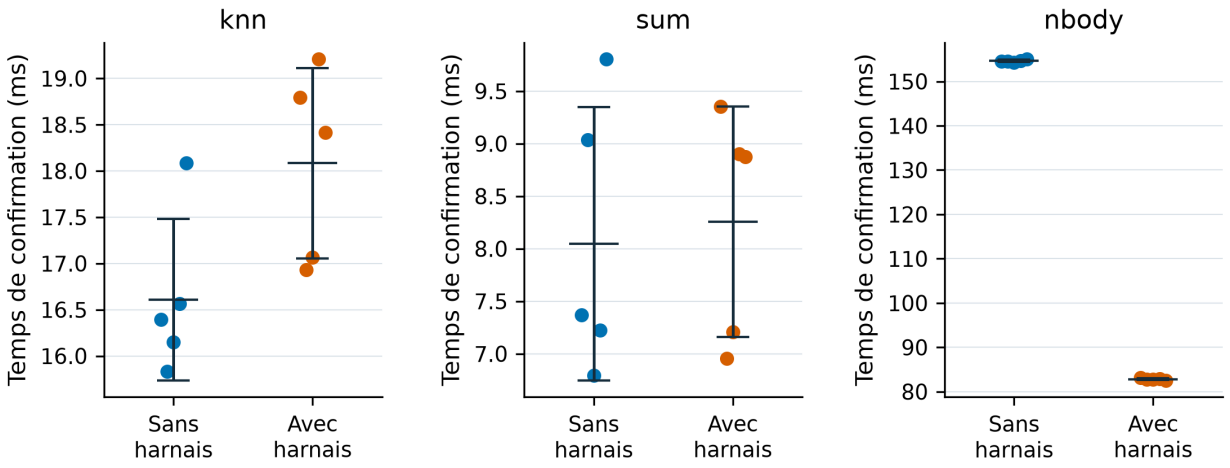


Figure 5 — Temps de confirmation des programmes retenus dans les six bras GPT, en millisecondes. Les cinq points par bras sont les répétitions d'un même programme ; le trait et la barre indiquent moyenne et écart-type empirique. L'échelle est propre à chaque sujet. Une recherche par bras ne permet pas d'estimer la variabilité de la recherche ni un effet causal du harnais.

Tableau 6 — Réductions normalisées par les références propres aux bras. L'écart descriptif n'est pas un effet causal estimé.

Sujet	Sans harnais : g (%)	Avec harnais : g (%)	Écart (points de %)
knn	99,19	99,12	-0,066
sum	93,62	93,71	0,081
nbody	76,65	87,50	10,850

L'archive contient 126 requêtes livrées, dont 125 appels natifs et une expiration sans appel de génération. Le total exact connu est de 3 218 520 jetons, avec huit appels non mesurés. Cinquante-trois contrôles internes de développement sont enregistrés, sans réparation autonome réussie ni lecture documentaire spontanée. Trois intégrations G de somme avec harnais ont expiré lors de l'incident de transfert ; les événements, les réponses tardives et les livraisons depuis le cache sont conservés sans rejeu. D'autres expirations bornées du témoin somme restent également documentées.

Cette comparaison démontre que les deux protocoles ont livré des programmes admissibles et mesurés sur les trois charges. Elle ne démontre pas que le harnais améliore généralement la recherche. L'absence de réplications indépendantes et l'exposition inégale aux incidents sont des facteurs de confusion explicites. Les écarts observés justifient des recherches répliquées ; ils ne constituent pas leur résultat.

3.6. GPT96 : recherche sans harnais, bornée par ses budgets

Les trois sujets de GPT96 sont reçus et audités avec cinq confirmations par référence et par finaliste admissible. Pour gpt-6.1-sol MAX sans assistance interne, les temps moyens de référence et du programme retenu sont respectivement 2,020260 et 0,014312 s sur k-NN, 0,126069 et 0,007741 s sur somme, puis 0,662318 et 0,061713 s sur N-body. Les réductions valent 99,29 %, 93,86 % et 90,68 %, sur les charges préparées de cette allocation. Les cinq temps, écarts-types, sources, parents et intégrations figurent en annexe D.1 et dans les trois forêts réelles de l'annexe G. Aucun nouveau diagnostic de montée en cœurs n'est ajouté pour ces exécutables.

Chaque sujet atteint son budget avant de terminer les 96 créneaux prévus : 54, 54 et 75 missions sont effectivement enregistrées. Les 183 missions comprennent 153 valides, 23 erreurs d'infrastructure, quatre échecs de génération, deux échecs de compilation et une annulation au budget. Les 155 sommets notés incluent les deux compilations échouées et ne sont donc pas tous chronométrés. Le code de sortie Slurm FAILED 1:0 traduit le planning incomplet du lanceur figé ; les trois pipelines ont néanmoins achevé leurs confirmations reçues. Aucun résultat négatif n'est rejoué.

Les 179 requêtes sont livrées et réconciliées, avec 177 invocations natives observées, 5 126 918 jetons exacts connus et 17 invocations sans compteur. Deux autres requêtes ont expiré avant toute invocation native établie. Le relais est arrêté après réception et audit. Le contexte natif de 65 536 et la réservation de 196 608 jetons par mission ne sont pas le paramètre de décodage des DeepSeek ; ces recherches ne forment pas une ablation strictement identique. Leur harnais désactivé ne correspond pas non plus au nouvel agent Codex avec outils, et elles ne constituent pas des cellules du nouveau bras source-only, distinct du préenregistrement historique 300 + 300.

3.7. Passage de un à seize cœurs

Les 10 lots CPU couvrent 58 campagnes, dix identités de modèles, sept sujets et 47 entrées distinctes. Tous les points reçus passent leurs contrôles exacts dans ce périmètre fini. La figure 6 illustre trois comportements complémentaires : une montée en cœurs importante de N-body, une évolution presque plate du bucket sort Luna, et un changement de classement entre accélération relative et temps absolu pour les deux programmes N-body GPT.

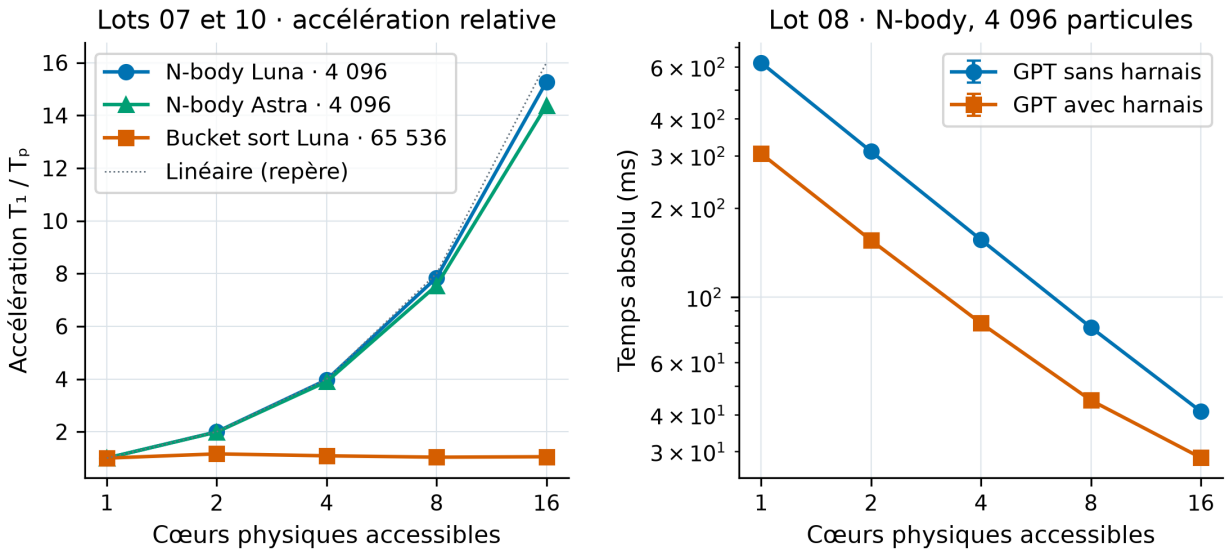


Figure 6 — Diagnostics de montée en cœurs à binaire et entrée constants. À gauche, accélération par rapport à un cœur : N-body Luna et Astra, 4 096 particules, lots 07 et 10, et bucket sort Luna, 65 536 éléments, lot 07 ; les rapports sont descriptifs, sans intervalle d'incertitude estimé. À droite, temps absolus des deux programmes N-body GPT, 4 096 particules, lot 08, avec l'écart-type des cinq temps. Chaque courbe conserve son allocation.

N-body Luna passe de 0,68080 s à un cœur à 0,04458 s à seize cœurs, soit S_{16} = 15,27 et E_{16} = 95,44 %. Son occupation moyenne CPU/mural atteint environ 14,84. Pour le bucket sort Luna, le programme retenu passe seulement de 0,00852 s à 0,00810 s : son gain important par rapport à la référence originale n'implique donc pas une montée en cœurs importante.

Le lot 10 retrouve cette distinction sur les exécutables Astra reçus : N-body passe de 0,66747 s à 0,04643 s, soit S_{16} = 14,38, avec une occupation moyenne d'environ 14,74 CPU. Aux plus grandes entrées respectives, les facteurs de k-NN, somme et bucket sort restent proches de un : 1,02, 1,06 et 1,04. Leurs gains contre la référence initiale ne suffisent donc pas à affirmer une utilisation efficace de seize cœurs. Ces rapports restent propres au lot 10 et ne constituent pas une comparaison de temps absolus avec le lot 07.

Les deux programmes N-body GPT illustrent une autre distinction. Dans le lot 08, le programme du bras sans harnais passe de 0,61908 s à 0,04104 s, soit 15,09 fois. Celui du bras avec harnais passe de 0,30514 s à 0,02863 s, soit 10,66 fois. Le second reste le plus rapide à seize cœurs malgré une accélération relative inférieure, parce qu'il est déjà plus rapide à un cœur. Comparer seulement les facteurs de montée en cœurs aurait masqué ce résultat.

Tropical et permutations sont beaucoup plus courts : leurs rapports T_1/T_{16} valent respectivement environ 1,10 et 1,23 sur leurs entrées de benchmark. Leurs occupations moyennes restent inférieures à un cœur, et la dispersion de mesure est importante relativement à ces différences. Ces chiffres ne permettent pas d'affirmer une parallélisation effective. Les annexes fournissent toutes les tailles, les temps absolus, les écarts-types et les références correspondantes, y compris les comportements sans amélioration.

3.8. Coût observé et résultats négatifs

Le tableau 7 sépare les consommations exactes connues, les appels sans mesure et les protocoles. Pour les quatorze ensembles natifs clos utilisés dans les résultats principaux, le total est de 1 701 appels, dont 154 non mesurés, et de 36 472 761 jetons exacts connus. Ce total est un minimum observé, pas une facture exhaustive. La requête historique Terra MAX expirée sans réponse possède une consommation inconnue ; elle reste distincte des 154 appels observés sans mesure et des deux requêtes GPT96 et des trois requêtes R1 Sol et des trois requêtes Sol source-only expirées avant invocation. Les nouvelles cohortes Terra distinguent aussi les réponses livrées, les claims interrompus déjà comptés dans les invocations non mesurées, et les demandes expirées sans preuve locale d'invocation. La figure 7 attribue les seuls jetons connus aux enfants, aux intégrations et à la mère, selon les rôles enregistrés.

Tableau 7 — Consommations natives connues. Les bornes budgétaires ne complètent pas les compteurs manquants.

Ensemble natif clos	Appels	Jetons exacts connus	Appels non mesurés
Count : vingt cellules	201	3 311 561	7
Luna : quatorze sujets	154	3 774 478	0
Astra : quatorze sujets	71	1 144 204	17
Terra : quatorze sujets	58	980 971	24
Sol : quatorze sujets	110	2 502 330	8
GPT : six bras	125	3 218 520	8
GPT96 : trois sujets	177	5 126 918	17
Source-only Luna MAX : quinze sujets	150	3 564 823	0
R1 Luna xhigh : quatorze sujets	158	3 434 224	0
Source-only Astra MAX : quinze sujets	98	1 856 292	13
R1 Astra xhigh : quatorze sujets	115	2 091 845	12
R1 Terra xhigh : quatorze sujets	104	1 966 540	7
Source-only Terra MAX : quinze sujets	59	823 583	31
Source-only Sol MAX : quinze sujets	121	2 676 472	10
Total des ensembles ci-dessus	1 701	36 472 761	154

Les deux nouvelles cohortes Terra conservent 8 requêtes non livrées : 2 claims interrompus, déjà inclus dans les invocations non mesurées, et 6 demandes sans preuve locale d'invocation. Ces dernières s'ajoutent aux inconnus des invocations observées, sans leur attribuer une consommation nulle.

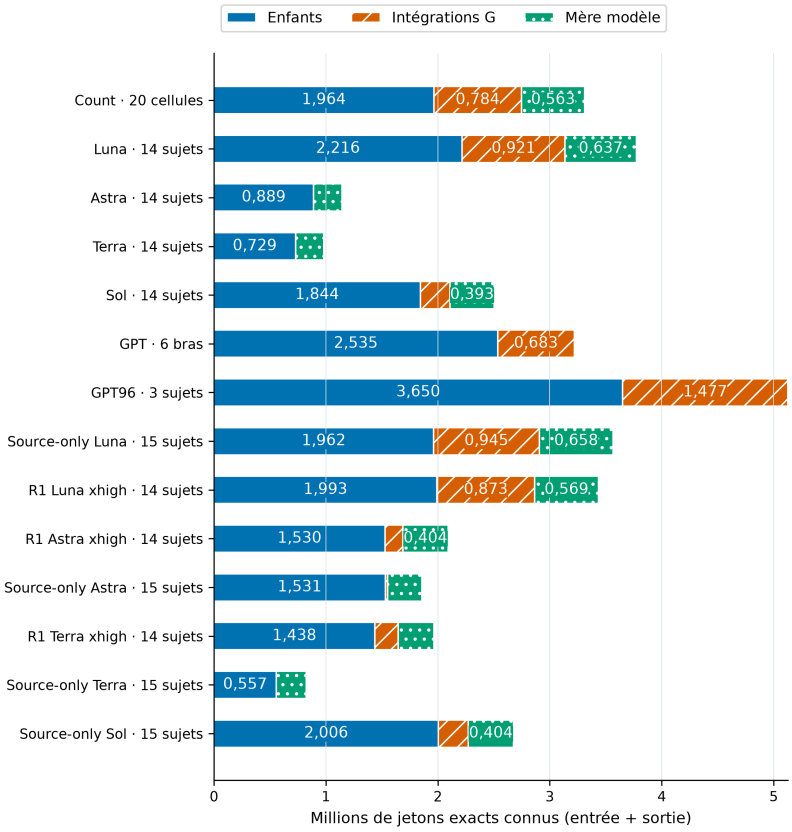


Figure 7 — Répartition des jetons natifs exacts connus dans les quatorze ensembles clos. Les segments distinguent les enfants, les intégrations G et la mère modèle. Les parties inconnues ne sont pas remplacées par les réservations. L'absence de mère modèle dans les six bras de comparaison et GPT96 est une différence de protocole. Les reçus clos Terra, GPT96, Sol R1 et Sol source-only remplacent leurs entrées historiques sans double compte. Cette figure décrit un coût observé ; elle ne classe pas l'efficacité générale des modèles.

Les campagnes exploratoires restent disponibles sans être assimilées aux cohortes principales. Les six recherches Qwen 1,5B/3B avec harnais n'ont confirmé aucun gain, malgré 54 requêtes d'optimisation et 447 778 jetons. Les sondes documentaires imposées sont séparées des lectures spontanées. Les sélections corrigées Qwen 32B conservent la référence sur k-NN et des gains plus modestes sur somme et N-body. Le pilote GPT 747664 possède une archive de recherche reçue, mais aucune confirmation finale vérifiée dans les données conservées ; son meilleur temps de recherche n'est pas présenté comme un gain confirmé. L'annexe H conserve les 42 résumés historiques avec leur statut et leurs limites, sans les ajouter à un échantillon homogène.

4. Discussion

4.1. Ce que les observations établissent

Les traces reçues montrent qu'une chaîne de génération, de recherche et de vérification peut produire des programmes sensiblement plus rapides que leurs références sur les charges préparées. Cette constatation dépend d'une sélection après confirmation : les résultats k-NN de DeepSeek 0731 montrent que le contrôle final peut supprimer entièrement un gain apparent de recherche. La conservation des références, des échecs et des finalistes exclus est donc une composante du résultat scientifique.

Les diagnostics CPU montrent également que réduction de travail, accélération par rapport à une référence et utilisation de plusieurs cœurs sont trois dimensions distinctes. Une optimisation qui réduit fortement le travail séquentiel peut laisser peu de calcul parallélisable sur une petite entrée. Inversement,

une bonne montée en cœurs ne garantit pas le meilleur temps absolu. Les figures de performance doivent permettre de lire ces deux aspects sans substituer un seul indicateur à l'autre.

4.2. Limites de validité interne et statistique

Une graine par cellule ne permet pas d'estimer la distribution des résultats d'une recherche stochastique. Les cinq mesures d'un finaliste réduisent l'incertitude sur son temps dans une allocation, mais ne créent pas cinq recherches indépendantes. Aucune valeur p, aucun intervalle de confiance entre modèles et aucun classement général ne sont donc calculés à partir de ces répétitions. Les écarts-types publiés restent descriptifs ; ils n'intègrent pas toute la variabilité entre jours, nœuds et décisions de recherche.

La confirmation réduit certains biais de sélection sans constituer une preuve universelle. Les finalistes ont été choisis après exploration, et leurs performances peuvent encore dépendre du benchmark préparé. Le contrôle exact des cas finis ne prouve pas la correction pour toutes les entrées légales. L'utilisation de sources publiques expose aussi à une possible connaissance préalable des problèmes par les modèles ; les recherches fraîches et l'absence de candidats hérités n'éliminent pas cette possibilité.

La comparaison du harnais possède en outre des incidents de transfert et des budgets effectivement consommés différents. Elle ne dispose ni de plusieurs graines ni d'un équilibrage expérimental suffisant pour isoler un effet causal. L'absence de consultation documentaire spontanée ou de réparation réussie dans ces six bras ne prouve pas que ces fonctions sont inutiles ; elle indique qu'elles n'ont pas contribué de manière observée dans ces recherches.

La disparition d'interfaces locales du 17 octobre conserve des requêtes sans réponse et des consommations inconnues. Les cohortes Terra closes ont exclusivement utilisé codex-cli 0.162.0-alpha.17.2. La cohorte Sol source-only reçue et auditée a utilisé le CLI copié 0.163.0-alpha.10.2, identifié par son empreinte ; les versions restent rapportées par cohorte. Cette transition doit rester une limite de contexte, sans attribution causale à une mise à jour ni mélange des cohortes.

4.3. Validité externe, conformité et reproductibilité

Les entrées, les compilateurs et la cible ARM64 décrivent une expérience adaptée. Ils ne reproduisent pas intégralement les matériels, les jeux, les formules de score et les règles des concours historiques. Aucun rang officiel n'est déduit. Les traces statiques SIMD ou OpenMP ne constituent pas une preuve d'instructions exécutées ou de threads utiles. MPI reste conditionnel aux sujets et aux préparations, sans résultat multinœud ou GPU de candidat revendiqué ici.

La conservation des sources, des empreintes, des registres et des réponses permet de reproduire les calculs et d'inspecter les décisions observables. Elle ne garantit pas qu'un service hébergé produira les mêmes programmes lors d'un nouvel appel. La reproductibilité documentaire, la répétabilité d'un chronométrage et la réplicabilité d'une recherche doivent donc rester distinguées. Les recommandations de benchmarking insistent précisément sur la description du contexte et des sources de variation [3, 5].

4.4. Expériences restantes

Le préenregistrement historique visait quinze sujets et vingt couples modèle–effort, soit 300 recherches source-only puis 300 avec le véritable agent Codex. La consigne humaine actuelle privilégie MAX uniquement : Luna, Astra, Terra et Sol source-only sont reçus et audités sur quinze sujets chacun, soit 60/60 MAX, en regard des 60/60 R1 MAX déjà reçus. Les 118 observations R1 historiques restent distinctes. Le véritable adaptateur Codex n'est pas admis par cette réception. Une seule graine, l'ordre temporel et les incidents limitent toute interprétation causale ; des réplications resteraient nécessaires pour établir une efficacité générale.

La priorité suivante est R2 : terminer les nombres premiers pour Sol, Luna, Astra et Terra MAX, puis étendre les quatre modèles aux quinze sujets de R1, soit soixante cellules neuves. Les nombres premiers restent un supplément hors de ces quinze sujets. Sol est reçu et audité après arrêt ; sa paire de programmes est remesurée indépendamment. Pour Astra, Terra et Luna, trois tentatives d'admission ont expiré avant tout appel natif. La dernière conserve 78 fichiers, dont les trois autorisations corrompues par le flux d'encodage local ; les authorization-ready sont absents et aucun worker n'a démarré. Le correctif ASCII et 23 empreintes après décodage sont validés localement, sans nouvelle réussite distante. La préparation suivante reste technique. Le tableau préparatoire distingue 60 confirmations historiques R1 et 60 cellules R2 non lancées (NA), soit aucune paire complète. Une absence de recherche n'est pas un gain nul.

R2g reste une tentative close partiellement, conservée sans rejeu et sans nouveau gain indépendant admis. R3 avec implémentation corrigée R4b reste une campagne distincte, bloquée techniquement ; ses contrats négatifs et ses coûts techniques sont conservés. La limite est quatre workers natifs. R5 doit être seul après clôture et réconciliation des autres générations, avec ses propres prérequis ; aucun R5/Flash appris n'est admis. L'échéance exclusive reste le 31 octobre 2026 à 23 h UTC, avec trois heures de réception et d'audit réservées avant tout nouveau maximum.

5. Conclusion

HPC-Forest met en évidence des améliorations confirmées sur des charges préparées, tout en montrant pourquoi la génération seule ne suffit pas à les établir. La sélection doit protéger les résultats négatifs, les références conservées et les rejets de confirmation. La comparaison des stratégies de recherche demande des réplications indépendantes ; la comparaison des exécutables demande des entrées, des binaires et des ressources précisément identifiés. Les 10 lots CPU complètent les gains de recherche par une mesure du comportement des programmes quand le nombre de cœurs augmente. L'ensemble fournit une base de preuves réanalysable pour les expériences suivantes, avec des conclusions limitées au périmètre effectivement reçu.

Disponibilité des données et transparence

Cette édition comprend un article principal, des annexes techniques, les données de confirmation recalculées, les 11 575 mesures CPU brutes et les comparaisons dérivées, ainsi qu'un index des sources et de leurs empreintes. Les archives antérieures restent conservées. Les données sont livrées avec le dossier de recherche local ; aucun dépôt public ou identifiant pérenne n'est revendiqué dans cette version. Les chemins techniques, identifiants de programmes, contrats détaillés et historiques se trouvent dans les annexes plutôt que dans le récit principal.

Le rapport est un instantané d'une étude en cours. Les modèles et outils d'IA interviennent dans la génération expérimentale et dans l'assistance à la préparation éditoriale ; les calculs présentés sont produits par des scripts déterministes à partir des traces conservées. Les sorties de modèles sont traitées comme des données à vérifier. L'article et ses analyses ne sont pas fournis comme contexte aux modèles des campagnes.

Références

[1] Inoue, Y., Misaki, K., Imajuku, Y., Kuroki, S., Nakamura, T. et Akiba, T. (2025). *Wider or Deeper? Scaling LLM Inference-Time Compute with Adaptive Branching Tree Search*. arXiv:2503.04412, version 5. Texte et métadonnées.

[2] Sakana AI. *TreeQuest — A Tree Search Library with Flexible API for LLM Inference-Time Scaling*. Implémentation utilisée : 0.3.2, vérifiée dans les environnements archivés. Dépôt de référence.

[3] Hoefler, T. et Belli, R. (2015). *Scientific Benchmarking of Parallel Computing Systems*. Proceedings of SC '15, article 73, 1–12. DOI : 10.1145/2807591.2807644. Notice des auteurs.

[4] SBC, Marathon de programmation parallèle. *Archives des énoncés, sources, règles et environnements 2020–2023*. 2020, 2021, 2022, 2023. Les copies consultées et leurs empreintes sont indexées en annexe A ; les adaptations expérimentales restent explicites.

[5] Kalibera, T. et Jones, R. (2013). *Rigorous Benchmarking in Reasonable Time*. Proceedings of ISMM '13, 63–74. DOI : 10.1145/2464157.2464160. Manuscrit et notice institutionnelle.